

QSNN / TEMP-DRIFT گزارش آموزشی و وضعیت پروژه

بر اساس کد و Results موجود در qsnn-main.zip — مناسب برای مرور شخصی و ارائه به سوپروایزر

خلاصه در یک جمله

حمله‌ها به‌درستی ساخته شده‌اند و Classical PGD می‌تواند QSNN را واقعاً گول بزند؛ اما دفاع‌هایی که تا Phase 17.2 امتحان شده‌اند هنوز به اندازه کافی پایدار و تکرارپذیر نیستند. مشکل مهم فعلی، ناپایداری مرز تصمیم بین کلاس‌های Versicolor و Virginica، به‌خصوص برای نمونه 119، و نحوه انتخاب checkpoint است.

1. پروژه دقیقاً چه کاری انجام می‌دهد؟

این پروژه یک شبکه عصبی اسپایکی-کوانتومی (QSNN) برای طبقه‌بندی دیتاست Iris می‌سازد. چهار ویژگی هر گل ابتدا نرمال می‌شوند، سپس با روش TTFS به زمان چهار اسپایک تبدیل می‌شوند، این زمان‌ها به زاویه‌های کوانتومی نگاشت می‌شوند و در نهایت یک مدار کوانتومی qubit-4 به همراه یک classifier سه‌کلاسه تصمیم می‌گیرد که گل متعلق به کدام گونه است.

مسیر ساده داده:

جریان پردازش

Iris features → Normalize → TTFS spike times → Quantum encoding → 4-qubit QSNN → Setosa / Versicolor / Virginica

بعد از ساخت مدل، پروژه دو سؤال اصلی دارد: 1) آیا با تغییر کوچک زمان اسپایک‌ها می‌توان مدل را فریب داد؟ 2) آیا می‌توان مدلی ساخت که در مقابل این تغییرات مقاوم‌تر باشد؟

2. دیتاست Iris چیست؟

Iris یک دیتاست کلاسیک و کوچک برای classification است. در کد پروژه، دیتاست اصلی از تابع load_iris در scikit-learn بارگذاری می‌شود؛ بنابراین فایل iris_input_example.csv دیتاست اصلی آموزش نیست.

ویژگی	مقدار
تعداد کل نمونه‌ها	150

تعداد ویژگی هر نمونه	4 ویژگی عددی
تعداد کلاس‌ها	3
نمونه در هر کلاس	50
Train	90 نمونه = 30 از هر کلاس
Validation	30 نمونه = 10 از هر کلاس
Held-out Test	30 نمونه = 10 از هر کلاس
Split seed	42

چهار ویژگی اندازه‌گیری شده عبارت‌اند از طول کاسبرگ (sepal length)، عرض کاسبرگ (sepal width)، طول گلبرگ (petal length) و عرض گلبرگ (petal width).

3. iris_input_example.csv چیست؟ آیا دیتاست ناقص است؟

خیر. این فایل فقط سه ردیف نمونه برای نشان دادن قالب ورودی دارد؛ دقیقاً یک نمونه از هر کلاس. کد training اصلاً این CSV را به‌عنوان دیتاست اصلی استفاده نمی‌کند. دیتاست کامل 150 نمونه‌ای از scikit-learn بارگذاری می‌شود.

نمونه خام چهار ویژگی	نام	کلاس
[0.2 , 1.4 , 3.5 , 5.1]	Setosa	0
[1.4 , 4.7 , 3.2 , 7.0]	Versicolor	1
[2.5 , 6.0 , 3.3 , 6.3]	Virginica	2

نتیجه مهم

نام iris_input_example.csv همراه‌کننده نیست؛ «example» یعنی فقط مثال. نبودن 147 ردیف دیگر در این فایل به معنی ناقص بودن دیتاست پروژه نیست.

4. TTFS و QSNN خیلی ساده

در TTFS، هر feature به زمان یک spike تبدیل می‌شود. در این پروژه قانون پایه $t = T \times (1 - x)$ است. feature بزرگ‌تر یعنی spike زودتر. با $T=100$ ، اگر feature نرمال شده 0.8 باشد، زمان spike برابر 20 می‌شود.

نمونه	Normalized features	TTFS spike times (T=100)
-------	---------------------	--------------------------

Setosa (ID 0)	[0.042 ,0.052 ,0.789 ,0.222]	[95.83 ,94.83 ,21.05 ,77.78]
Versicolor (ID 50)	[0.542 ,0.621 ,0.632 ,0.750]	[45.83 ,37.93 ,36.84 ,25.00]
Virginica (ID 100)	[1.000 ,0.845 ,0.684 ,0.556]	[0.00 ,15.52 ,31.58 ,44.44]

QSNN فعلی 4 qubit و 4 لایه variational دارد. 32 پارامتر کوانتومی و 15 پارامتر classifier دارد؛ در مجموع فقط 47 پارامتر trainable. این کوچک بودن برای یک آزمایش مفهومی روی Iris مناسب است.

5. حمله و دفاع یعنی چه؟

حمله یعنی زمان اسپایک‌ها را در یک بودجه محدود کمی تغییر بدهیم تا prediction مدل عوض شود. دفاع یعنی مدل را طوری آموزش دهیم که همان تغییر کوچک نتواند به راحتی prediction را عوض کند.

حالت	مثال مفهومی
Clean	✓ spikes → QSNN → Virginica
Attack	✗ spike times → QSNN → Versicolor کمی تغییر در
Defense مطلوب	✓ Virginica → QSNN مقاوم → spikeهای تغییرکرده

6. معنی metric ها و اینکه چه مقداری خوب است

Metric	معنی ساده	چه چیزی خوب است؟	وضعیت فعلی مهم
Clean Accuracy	درصد پاسخ درست روی داده سالم	هرچه بالاتر بهتر؛ در پروژه sanity $\geq 85\%$	Test baseline فاز 14: 86.67%؛ validation بعضی seedها تا 96.67%
Macro F1	تعداد عملکرد بین سه کلاس	نزدیک 1 بهتر	معمولاً نزدیک Accuracy بوده
ASR	درصد نمونه‌های clean- correct که attack خراب می‌کند	از دید دفاع: نزدیک 0 بهتر؛ از دید مهاجم: بالاتر بهتر	Classical PGD در 10%: 34.62% روی baseline تست
Trace Distance	فاصله کوانتومی دو state ورودی	برای attack بالاتر = drift بیشتر؛ دفاع لزوماً نمی‌تواند input-state آن را کم کند	در 10% PGD حدود 0.156

Fidelity – 1	0 یعنی دو حالت یکسان؛ بزرگ‌تر یعنی drift بیشتر	برای attack بزرگ‌تر؛ برای پایداری representation کوچک‌تر	PGD 10% حدود 0.0244
Delta_cls	تغییر کلاسیک spike statistics	برای stealth پایین بهتر	metric فعلی coarse است و نباید بیش‌ازحد تفسیر شود
Margin	فاصله logit کلاس درست از قوی‌ترین رقیب	مثبت و بزرگ بهتر؛ نزدیک صفر شکننده؛ منفی یعنی سمت رقیب	sample 119 baseline فقط ~ 0.001 تا 0.005
Paired net gain	rescued – broken روی همان نمونه‌ها	مثبت و تکرارشونده در seedهای مختلف مطلوب	بهبودها عموماً +1 و sparse بوده‌اند

7. نتایج حمله‌ها – Phase 14

این بخش از پروژه موفق است: attack pipeline درست کار می‌کند، وزن‌های مدل در حمله ثابت می‌مانند و بودجه زمانی رعایت می‌شود. Classical PGD قوی‌ترین حمله برای خراب کردن classification بوده است.

ϵ	Random ASR	Classical PGD ASR	Reference TEMP-DRIFT ASR
1%	0%	7.69%	0%
2%	0%	7.69%	0%
5%	0%	19.23%	3.85%
10%	3.85%	34.62%	11.54%

در Classical PGD، $\epsilon=10\%$ ، ϵ توانسته 9 نمونه از 26 نمونه clean-correct را خراب کند. این یعنی حمله واقعاً مؤثر است و پروژه یک مسئله robustness واقعی برای بررسی دارد.

Gradient TEMP-DRIFT نیز prediction flip ایجاد کرده و تمام خروجی‌های نهایی constraint را رعایت کرده‌اند، اما از نظر quantum drift همیشه از reference بهتر نبوده است. بنابراین implementation موفق است ولی superiority علمی آن هنوز قطعی نیست.

8. آزمایش‌های دفاع و نتیجه هر مرحله

مرحله	هدف	وضعیت اجرا	نتیجه علمی	خلاصه
Phase 15	Fidelity-based QUANTUM-TEMP	فنی: موفق	علمی: ناموفق	دقت clean ثابت ماند، ولی ASR هیچ حمله‌ای کم نشد.
Phase 15.1	تنظیم λ_q و λ_{pred}	فنی: موفق	علمی: ناموفق/مختلط	$\lambda_q=5$ روی validation کمی بهتر؛ test clean 86.67→83.33 و معیار موفقیت رد شد.
Phase 15.2	Paired sample analysis	تشخیصی: موفق	دفاع: ضعیف	بهبود 5% PGD حذف شد؛ در 10% فقط یک rescue واقعی باقی ماند.
Phase 15.3	seed replication-5	تشخیصی: موفق	دفاع: seed-sensitive	10% PGD فقط 2/5 seed بهتر؛ median net .gain=0
Phase 16	JS + Margin + Quantum	فنی: موفق	NO-GO	seed42 بهتر؛ seed777 بدون بهبود؛ seed2026 افت clean؛ test باز نشد.
Phase 17	Adversarial timing training (PGD-1)	فنی: موفق	NO-GO	PGD ASR پایین‌تر، اما clean stability بین seedها حفظ نشد.
Phase 17.1	تنظیم λ_{adv}	فنی: موفق	ناموفق	کم کردن λ_{adv} مشکل small-epsilon و class 2 را حل نکرد.
Phase 17.2	تحلیل boundary و sample119	تشخیصی: موفق	نتیجه ریشه‌یابی	119 ذاتاً low-margin؛ seed777 checkpoint seed2026؛ issue .boundary compression

9. دفاع‌ها چرا هنوز موفق نشده‌اند؟

Phase 15 نشان داد loss کوانتومی خیلی ضعیف‌تر از Cross-Entropy است. حتی $\lambda q=20$ فقط حدود 0.16% از CE را تشکیل می‌داد. بنابراین مدل تقریباً انگیزه‌ای برای تغییر تصمیمات خود از این loss نمی‌گرفت.

Phase 16 loss‌های مستقیم‌تر JS و margin را اضافه کرد، اما در چند seed نتیجه یکسان نبود. این یعنی مسئله فقط انتخاب یک loss بهتر نیست؛ geometry مرز تصمیم مدل هم حساس است.

Phase 17 مستقیماً با adversarial PGD آموزش داد. این روش واقعاً gradient قوی ایجاد کرد و PGD ASR را پایین آورد، اما در بعضی seedها clean accuracy افت کرد و در ۴‌های کوچک حتی چند failure جدید به وجود آمد. یعنی clean performance و robustness هنوز trade-off نامطلوب دارند.

10. داستان Sample 119 – آیا خودش ایراد دارد؟

Sample 119 یک نمونه واقعی از دیتاست استاندارد Iris و در validation split است؛ فایل example.csv نقشی در آن ندارد. اطلاعات خام آن:

ID	True class	Raw features	Normalized	TTFS times
119	Virginica (2)	[1.5 ,5.0 ,2.2 ,6.0]	[0.105 ,0.472] [0.583 ,0.672]	[89.47 ,52.78] [41.67 ,32.76]

این نمونه «خراب» یا mislabeled شناخته نشده؛ مشکل این است که در فضای مدل به مرز Versicolor/Virginica بسیار نزدیک است. baseline margin در seedهای 777 و 2026 فقط حدود 0.00496 و 0.00103 بوده؛ یعنی با تغییر بسیار کوچک در پارامترها یا checkpoint می‌تواند سمت کلاس 1 برود.

رفتار training هم این را تأیید می‌کند: sample 119 حتی در baseline در بعضی epochها اشتباه می‌شود و بعد دوباره برمی‌گردد. پس defense این شکنندگی را از صفر ایجاد نکرده؛ گاهی آن را تشدید کرده است.

جمع‌بندی sample 119

119 یک boundary case واقعی است، نه مدرک ناقص بودن دیتاست. نباید کل defense را برای درست کردن یک نمونه طراحی کنیم؛ اما این نمونه ابزار خوبی برای فهم ناپایداری مرز کلاس 1 و 2 است.

11. مهم‌ترین اعداد فعلی را چطور بخوانیم؟

مورد	مقدار فعلی	حالت مطلوب	برداشت
Baseline test accuracy (Phase14)	86.67%	$\leq 85\%$ برای sanity؛ بالاتر بهتر	مدل پایه قابل استفاده است.
Seed42 validation accuracy	96.67%	نزدیک baseline و بدون افت $2pp <$	خوب، ولی یک seed کافی نیست.
Classical PGD ASR 10% baseline	34.62%	برای دفاع باید واضح پایین بیاید	attack قوی و meaningful است.
Phase15 defense ASR	بدون تغییر	کاهش ASR	ناموفق.
Fidelity $\lambda q=5$ test clean	83.33%	افت $2pp \geq$ از baseline	افت 3.33pp؛ gate fail.
Multi-seed fidelity PGD10	2/5 seed بهتر	اکثریت seedها بهتر	ضعیف و seed-sensitive.
Phase17 seed42 mean PGD ASR	7.76%→11.21%	کاهش بدون افت clean	امیدبخش فقط در seed42.
Phase17 seed777 clean	93.33%→96.67%	افت $2pp \geq$	افت 3.33pp؛ fail.
Phase17 seed2026 clean	90.00%→93.33%	افت $2pp \geq$	افت 3.33pp؛ fail.
Sample119 margin	$\sim 0.005-0.001$ baseline در بعضی seedها	مثبت و با فاصله مناسب از صفر	بسیار شکننده.

12. چه چیزهایی تا الان واقعاً موفق بوده‌اند؟

- زیرساخت encoding، TTFS، QSNN، کوانتومی و training به‌صورت تست‌شده کار می‌کنند.
- Phase 14 attack framework موفق است؛ Classical PGD یک attack واقعی و قوی ایجاد می‌کند.
- Gradient TEMP-DRIFT از نظر پیاده‌سازی feasible و gradient-based است و prediction flip ایجاد می‌کند.
- Paired analysis جلوی نتیجه‌گیری اشتباه از denominator متفاوت را گرفته است.
- Multi-seed evaluation نشان داده کدام نتیجه‌ها seed-specific هستند؛ این از نظر علمی مهم است.
- No-test gates در Phase 16/17/17.1/17.2 رعایت شده‌اند؛ بنابراین held-out test برای توسعه‌های جدید مصرف نشده است.

- Phase 17.2 علت محتمل ناپایداری را از «loss conflict» به سمت boundary/checkpoint fragility محدود کرده است.

13. چه چیزهایی هنوز موفق نشده‌اند؟

- هنوز defense نهایی و تکرارپذیری نداریم که بتوانیم در مقاله ادعا کنیم QSNN را robust کرده است.
- Fidelity-only defense اثر بسیار ضعیفی داشت.
- JS/margin با random jitter بین seedها پایدار نشد.
- Adversarial training مؤثرتر است ولی clean/robustness trade-off را هنوز حل نکرده است.
- بهبودهای paired غالباً کوچک بوده‌اند؛ معمولاً یک یا دو sample و بدون significance کافی.
- Metric کلاسیک ISI/Delta_cls برای فقط چهار timing coarse است؛ stealth claim قوی نباید فعلاً روی آن بنا شود.

14. الان دقیقاً در کدام مرحله‌ایم؟

وضعیت فعلی

آخرین Result موجود در فایل آپلودی Phase 17.2 است. فایل‌های کد و تست Phase 17.3 وجود دارند، اما result نهایی Phase 17.3 در ZIP دیده نمی‌شود؛ بنابراین بر اساس سند موجود، Phase 17.3 مرحله بعدی/در حال اجرا محسوب می‌شود.

Phase 17.3 قرار است بدون تغییر training فقط بررسی کند آیا انتخاب checkpoint مقاوم‌تر می‌تواند بخشی از مشکل seed 777 را حل کند. این کار نباید مخصوص sample 119 rule باید generic و validation-only باشد.

15. مراحل باقی‌مانده پیشنهادی

ترتیب	مرحله	هدف	شرط رفتن جلو
1	Phase 17.3 — Robust checkpoint selection	انتخاب epoch با توجه به accuracy، class stability، PGD validation و margin	بهبود یا حفظ clean در همه seedها و عدم بدترشدن small-ε
2	اگر 17.3 فقط seed777 را حل کرد	تحلیل جداگانه compression در seed2026	مشخص شود مشکل boundary عمومی است یا

			seed-specific
3	Freeze protocol	بعد از یک validation rule موفق، تمام تنظیمات قفل شوند	هیچ tuning جدید با test انجام نشود
4	Final held-out evaluation	یک بار ارزیابی نهایی روی test	paired analysis + multi-seed clean و rescued > broken cost محدود
5	Paper-ready analysis	جدول attack/defense، ablation، limitations statistical caution	فقط claimهایی که واقعاً توسط نتایج پشتیبانی می‌شوند

16. اگر بخواهیم در پایان بگوییم «دفاع موفق است»، چه چیزی باید ببینیم؟

به صورت ساده، یک defense قابل دفاع باید بیشتر این شرایط را همزمان داشته باشد:

- Clean accuracy تقریباً حفظ شود؛ افت ترجیحاً $2 \geq \text{percentage points}$.
- در بیشتر seedها—not فقط ASR—seed42 حمله PGD کم شود.
- در paired comparison تعداد rescued از broken بیشتر باشد.
- بهبود در چند epsilon معنی دار دیده شود، نه فقط یک نقطه.
- کلاس 1 یا 2 به قیمت robustness کلاس دیگر خراب نشود.
- نتیجه روی held-out test بعد از freeze شدن protocol تأیید شود.
- اگر sample count کم است، ادعا با احتیاط آماری نوشته شود.

17. برداشت نهایی برای کسی که اولین بار این موضوع را کار می‌کند

شما تا اینجا «شکست نخوردید». بخش بزرگی از کار پژوهشی دقیقاً پیدا کردن این است که چه چیزی جواب نمی‌دهد و چرا. پروژه اکنون چند نتیجه معتبر دارد: attack واقعی ساخته شده، چند defense بررسی شده، نتیجه‌های ظاهری با paired analysis اصلاح شده، seed sensitivity کشف شده و اکنون ریشه‌ی یکی از failureهای مهم به decision boundary و checkpoint selection محدود شده است.

در حال حاضر بهترین جمله علمی این نیست که «QUANTUM-TEMP مدل را robust کرد». جمله دقیق‌تر این است که «decision-aware و fidelity-only ایجاد می‌کنند؛ adversarial timing training سیگنال قوی‌تری دارد اما هنوز regularization ساده robustness پایدار ایجاد نکردند؛ trade-off و seed sensitivity دارد».

این وضعیت برای ادامه تحقیق مناسب است، چون دقیقاً می‌دانیم مرحله بعد باید چه سؤال محدودی را پاسخ دهد، بدون اینکه test set را برای tuning مصرف کنیم.

18. واژه‌نامه خیلی کوتاه

واژه	معنی خیلی ساده
QSNN	مدلی که بخش کوانتومی + classifier دارد و ورودی زمانی اسپایک را پردازش می‌کند.
TTFS	اطلاعات را در «زمان اولین spike» کد می‌کند.
Clean	ورودی بدون attack.
Attack	تغییر کنترل‌شده ورودی برای ایجاد خطا.
Defense	روش training/regularization برای مقاومت در برابر attack.
PGD	حمله gradient-based که مرحله‌به‌مرحله ورودی را برای زیاد کردن loss تغییر می‌دهد.
Seed	عدد کنترل randomness؛ اگر روش فقط در یک seed خوب باشد، نتیجه قابل اعتماد نیست.
Validation	بخش داده برای انتخاب تنظیمات؛ نباید با test قاطی شود.
Held-out test	داده‌ای که فقط بعد از freeze شدن روش باید برای ارزیابی نهایی استفاده شود.
Checkpoint	وزن‌های ذخیره‌شده مدل در یک epoch خاص.
Margin	فاصله تصمیم کلاس درست از نزدیک‌ترین رقیب.
Paired analysis	مقایسه دو مدل روی دقیقاً همان sample‌ها.

19. منابع این گزارش در پروژه

این گزارش از فایل‌های واقعی پروژه تهیه شده است، به‌ویژه: `experiments/iris/data.py`، `README_FA.md`، `data/sample/iris_input_example.csv` و Results فازهای 14، 15، 15.1، 15.2، 15.3، 16، 17، 17.1 و 17.2. هیچ نتیجه‌ای برای Phase 17.3 در ZIP موجود نبود، هرچند کد و تست آن وجود دارد.